

Lab 03: Word Embedding

6. Bài tập tính toán:

Bài 1: - Co-occurrence

$V = \{ \text{the, cat, rats, fish, dog, likes, milk, meat} \}$

$\vec{\text{cat}} = \{ 2, 0, 1, 0, 0, 1, 0, 0 \}$

$\vec{\text{dog}} = \{ 2, 0, 1, 0, 0, 1, 0, 0 \}$

$\vec{\text{rats}} = \{ 0, 1, 0, 2, 1, 0, 0, 0 \}$

$\vec{\text{likes}} = \{ 0, 1, 0, 0, 1, 0, 1, 1 \}$

Bài 2: Similarity:

$$\cos(x, y) = \frac{x \cdot y}{\|x\| \cdot \|y\|} = \frac{1 \cdot 2 + 2 \cdot 1 + 1 \cdot 2}{\sqrt{1^2 + 2^2 + 1^2} \cdot \sqrt{2^2 + 4^2 + 2^2}} = 1$$

⇒ Hai vectơ có độ lớn khác nhau nhưng Cosine Similarity = 1 có nghĩa là hai vectơ có tỷ lệ phân bố đại trưng gần nhau, cũng biểu diễn một nội dung hoặc chủ đề. Vectơ lớn hơn do tần suất xuất hiện nhiều hơn từ của văn bản.

Gemma

Learning is the eye of the mind



7. Bài 3 - So sánh semantic similarity.

$$\begin{aligned}\cos(\text{doctor}, \text{physician}) &= \frac{v_{\text{doctor}} \cdot v_{\text{physician}}}{\|v_{\text{doctor}}\| \cdot \|v_{\text{physician}}\|} \\ &= \frac{0.8 \times 0.7 + 0.1 \times 0.2 + 0.7 \times 0.8}{\sqrt{0.8^2 + 0.1^2 + 0.7^2} \cdot \sqrt{0.7^2 + 0.2^2 + 0.8^2}} \approx 0.9871\end{aligned}$$

$$\begin{aligned}\cos(\text{doctor}, \text{banana}) &= \frac{v_{\text{doctor}} \cdot v_{\text{banana}}}{\|v_{\text{doctor}}\| \cdot \|v_{\text{banana}}\|} \\ &= \frac{0.8 \times (-0.2) + 0.1 \times (0.9) + 0.7 \times (-0.1)}{\sqrt{0.8^2 + 0.1^2 + 0.7^2} \cdot \sqrt{(-0.2)^2 + (0.9)^2 + (-0.1)^2}} \approx -0.1414\end{aligned}$$

⇒ "doctor" gần với "physician"

8. Bài 4 - Sparse vs dense.

$$\sqrt{10.8^2 + 0.1^2 + 0.7^2}, 10.0.21 \dots$$

⇒ "doctor" gần từ "physician"

8. Bài 4 - Sparse vs dense.

$V = 10,000$; word - context : 10,000 dims - 30 non-zero.

1. Biểu diễn sparse : biểu diễn word - context representation

Vì vector này có số chiều rất lớn nhưng chỉ có số giá trị khác 0. Sự thưa thớt này là đặc trưng cho biểu diễn phân phối xuất hiện.

2. Biểu diễn dense : biểu diễn Embedding. Do vector này có kích thước nhỏ hơn nhiều và hầu như các thành phần đều chứa giá trị khác 0, thông tin sẽ được nén lại vào 1 9 gran vector duy nhất.

3. Dense representation có thể thuận lợi hơn cho semantic similarity vì:

- Vượt qua rào cản trùng lặp từ ngữ (Lexical Match)
- Biểu diễn đặc trưng ẩn (Distributed / Latent Features)
- Tính ổn định và bộ nhớ.

4. Dense representation không phải lúc nào cũng tốt hơn sparse. Tuy vậy bài toán thực tế, sparse vẫn có những ưu thế như:

- Khả năng giải thích : sparse (mỗi chiều tương ứng trực tiếp với 1 từ / token), dense (các chiều là đặc trưng ẩn, không giải thích trực tiếp từng số thuộc đại diện cho nét nghĩa nào. Gemma

Learning is the eye of the mind



- Bài toán tìm kiếm chính xác từ khóa:
- Phụ thuộc vào dữ liệu huấn luyện: Dense embedding (như Word2Vec)
yêu cầu lượng corpus đủ lớn để học được các mánh không gian vectơ.
Nếu dữ liệu quá ít, vectơ dense học ra có thể bị lệch hoặc nhiễu.

doctor - 1. physician (0.82)

- 知

Q3. bar by fish analogy

→ vectơ mới có thể tại diện của ~~quan hệ~~ tu "queen". Và chúng mình cũng không quên vectơ của W2V đặc biệt thuộc ảnh tuyến ảnh.

- 3 similarity dup:

- ①. medica → physicians